2026 년 문서 파싱 고도화 계획

작성: 문서 파싱 TF ｜ 참고: Docling 저장소

1. 추진 배경

□ 문서 파싱 품질 문제

○ 표 구조 손실: 병합 셀이 Markdown 변환 과정에서 사라짐

- 예산표, 결재란 등 업무 문서의 핵심 정보 누락

- 화면 표시와 LLM 입력 모두 품질 저하

○ 한국어 띄어쓰기 소실

※ 디지털 PDF 기준 어절 일치율 11.4%

□ 처리 속도 문제

○ 스캔 문서 OCR 이 전체 처리 시간의 대부분을 차지

2. 추진 계획

1. 통합 문서 모델 구축

    가. DOCX 파서 개발

        1) 문단과 서식

            가) 자동 번호

            나) 셀 병합

        2) 도형과 순서도

    나. HWPX 파서 개발

2. 화면 표시 품질 검증

3. 예산 계획

구분	**2026** 년		
	상반기	하반기	합계
인건비	10	12	22
장비비	5	7	12
합계	15	19	34

(단위: 억원)

4. 실적 추이

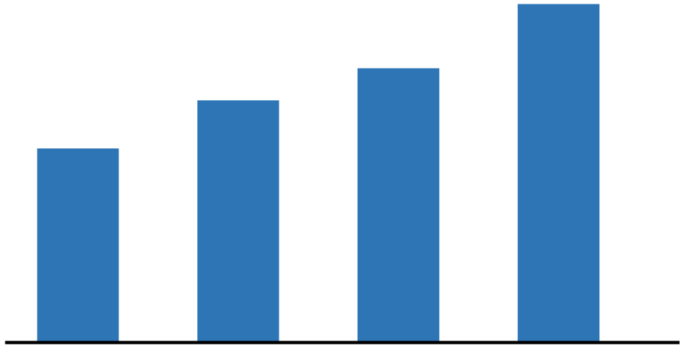
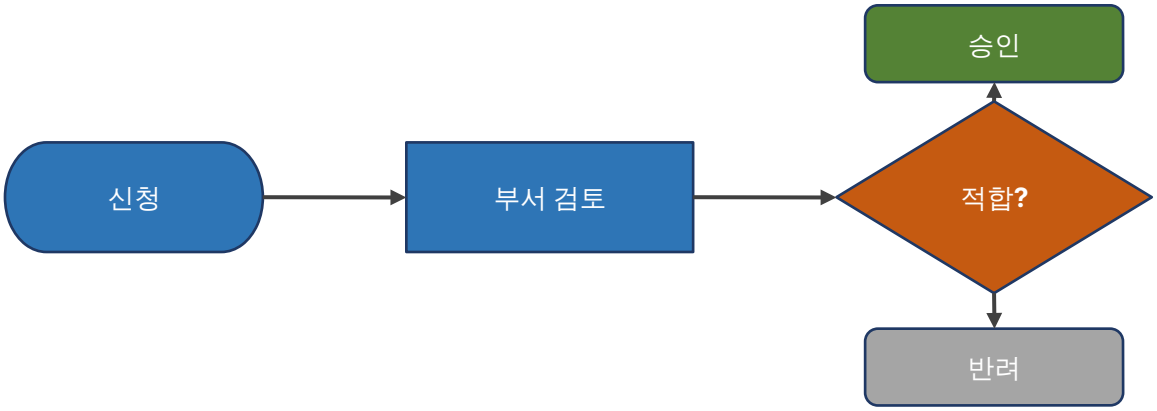


그림 1. 분기별 처리 건수

5. 결재 절차



※ 반려 시 신청 단계로 돌아갑니다.